

Bayesianische Regression

lineare und logistische Modelle

Lona Koers

LMU

25. Juli 2025

- 1 Motivation und Intuition
- 2 Bayesianische lineare Modelle
- 3 Bayesianische **generalisierte** lineare Modelle
- 4 Posterior Inference

TODO: gutes Beispiel

- Generalisierte Lineare Modelle (GLMs)
- Punktvorhersage vs. Verteilung vorhersagen
- warum reicht uns ein CI / PI

- 1 Motivation und Intuition
- 2 Bayesianische lineare Modelle
- 3 Bayesianische **generalisierte** lineare Modelle
- 4 Posterior Inference

Annahmen:

- ① i.i.d. Daten $\mathbf{D} = (\mathbf{y}, \mathbf{X})$
- ② Kondition auf \mathbf{X} (implizit)

Frequentistisches lineares Modell: $\mathbf{y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$

- ③ Gewichtsparameter $\boldsymbol{\theta}$ als Zufallsvariable interpretieren

Bayesianisches lineares Modell:

$$\mathbf{y} \mid \boldsymbol{\theta}, \sigma^2 \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$$

Prior-Annahme für θ (und evtl. σ^2) notwendig \rightarrow sehr vielseitige Modell-Anpassung möglich

1. Normal-Invers-Gamma Prior:

$$\theta \mid \sigma^2 \sim \mathcal{N}(\check{\mu}, \sigma^2 \check{\Sigma})$$

$$\sigma^2 \sim \text{IG}(\check{a}, \check{b})$$

$$\theta, \sigma^2 \sim \text{NIG}(\check{\mu}, \sigma^2 \check{\Sigma}, \check{a}, \check{b})$$

mit Prior Parametern: $\check{\mu}$, $\check{\Sigma}$, \check{a} und \check{b}

Vorteil: NIG-Prior ist mit Normalverteilungs-Likelihood konjugiert \rightarrow exakte Inferenz möglich
(mehr dazu später)

TODO: Bild

2. Uninformative Prior

z.B. mit NIG-Prior mit Prior Parametern

$$\check{\boldsymbol{\mu}} = \mathbf{0}, \quad \check{\boldsymbol{\Sigma}}^{-1} = \mathbf{0} \text{ i.e., } \check{\boldsymbol{\Sigma}} \rightarrow \infty$$
$$\check{a} = -\frac{p}{2}, \quad \check{b} = 0$$

\implies flache (und damit uninformative) Prior und maximaler Einfluss der Daten auf die Posterior:

$$\boldsymbol{\theta} \mid \sigma^2 \stackrel{a}{\sim} \mathcal{N}(\check{\boldsymbol{\mu}}, \sigma^2 \infty) \implies p(\boldsymbol{\theta} \mid \sigma^2) \propto 1$$

TODO: Bild

Erinnerung: *frequentistische* Regularisierung durch Minimierung von

$$\text{PLS}(\boldsymbol{\theta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) + \lambda \text{pen}(\boldsymbol{\theta})$$

mit Regularisierungs-Parameter $\lambda > 0$.

Bayesianische Regularisierung durch Wahl der Prior-Verteilung für $\boldsymbol{\theta}$

3. Ridge Regularisierung

Frequentistisch: $\text{pen}(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_2^2$ TODO quote

Bayesianisch: $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$ mit $\tau^2 \propto \frac{1}{\lambda}$

TODO quote

4. Lasso Regularisierung

Frequentistisch: $\text{pen}(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_1$

Bayesianisch:

$$\boldsymbol{\theta} \mid \tau^2 \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$$

$$\tau_j^2 \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(0.5\lambda^2), \quad j = 1, \dots, p$$

Problem: keine Variablenselektion (im Gegensatz zu frequentistischem Lasso)

→ Alternative Priors für Variablenselektion: Spike and Slab, Horseshoe, u.v.m.

Vorteile von bayesianischer Regularisierung sind u.a.:

- Probabilistisches Modell trotz Regularisierung
- Regularisierungsparameter muss nicht als Hyperparameter optimiert werden (z.B. durch Prior auf τ^2)
- Mehr Anpassungsmöglichkeiten durch Prior-Spezifikation

TODO: Bild regularization Priors + update

- 1 Motivation und Intuition
- 2 Bayesianische lineare Modelle
- 3 Bayesianische **generalisierte** lineare Modelle
- 4 Posterior Inference

Bayesianisches LM \rightarrow GLM (alt: Generalisierung des bayesianischen linearen Modells)



- 1 Motivation und Intuition
- 2 Bayesianische lineare Modelle
- 3 Bayesianische **generalisierte** lineare Modelle
- 4 Posterior Inference

Erinnerung: Bayes-Regel

$$p(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{\int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}},$$

wobei $p(\mathbf{y} \mid \boldsymbol{\theta})$ die Modell-Likelihood ist.

bayesianisches LM: exakte Inferenz mit konjugierten Prioris

Metropolis Hastings (MCMC)

Idee: Approximation der Posterior mit Markov chain Monte Carlo - was muss man für Regression anpassen?

Laplace Approximation (LA)

Idee: Approximation der Posterior mit einer Normalverteilung

- Mittelwert und Varianz werden mit IWLS berechnet

PPD

Falls euch das Thema interessiert und ihr mehr wissen wollt, kann ich folgende Literatur empfehlen:

- Bayesianische Regression (v.a. für praktische Anwendung): Gelman et al. [3]
- Prior Verteilungen (v.a. Shrinkage): Erp, Oberski, and Mulder [2] und Celeux et al. [1]
- Software: z.B. brms in R, PyMC in python

- [1] Gilles Celeux et al. “Regularization in Regression: Comparing Bayesian and Frequentist Methods in a Poorly Informative Situation”. In: *Bayesian Analysis* 7.2 (June 2012), pp. 477–502. ISSN: 1936-0975, 1931-6690. DOI: 10.1214/12-BA716.
- [2] Sara van Erp, Daniel L. Oberski, and Joris Mulder. “Shrinkage priors for Bayesian penalized regression”. In: *Journal of Mathematical Psychology* 89 (Apr. 2019), pp. 31–50. ISSN: 0022-2496. DOI: 10.1016/j.jmp.2018.12.004.
- [3] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. New York: Chapman and Hall/CRC, 2013. ISBN: 978-0-429-11307-9. DOI: 10.1201/b16018.