

Bayesianische Regression

lineare und logistische Modelle

Lona Koers

LMU

25. Juli 2025

TODO: gutes Beispiel

- Generalisierte Lineare Modelle (GLMs)
- Punktvorhersage vs. Verteilung vorhersagen
- warum reicht uns ein CI / PI

1 Bayesianische **lineare** Modelle

2 Bayesianische **generalisierte** lineare Modelle (GLMs)

3 Posterior Inference

Annahmen:

- ① i.i.d. Daten $\mathbf{D} = (\mathbf{y}, \mathbf{X})$
- ② Kondition auf \mathbf{X} (implizit)

Frequentistisches lineares Modell: $\mathbf{y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$

- ③ Gewichtsparameter $\boldsymbol{\theta}$ als Zufallsvariable interpretieren

Bayesianisches lineares Modell:

$$\mathbf{y} \mid \boldsymbol{\theta}, \sigma^2 \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$$

Prior-Annahme für θ (und evtl. σ^2) notwendig \rightarrow sehr vielseitige Modell-Anpassung möglich

1. Normal-Invers-Gamma Prior:

$$\theta \mid \sigma^2 \sim \mathcal{N}(\check{\mu}, \sigma^2 \check{\Sigma})$$

$$\sigma^2 \sim \text{IG}(\check{a}, \check{b})$$

$$\theta, \sigma^2 \sim \text{NIG}(\check{\mu}, \sigma^2 \check{\Sigma}, \check{a}, \check{b})$$

mit Prior Parametern: $\check{\mu}$, $\check{\Sigma}$, \check{a} und \check{b}

Vorteil: NIG-Prior ist mit Normalverteilungs-Likelihood konjugiert \rightarrow exakte Inferenz möglich
(mehr dazu später)

TODO: Bild

2. Uninformative Prior

z.B. mit NIG-Prior mit Prior Parametern

$$\check{\boldsymbol{\mu}} = \mathbf{0}, \quad \check{\boldsymbol{\Sigma}}^{-1} = \mathbf{0} \text{ i.e., } \check{\boldsymbol{\Sigma}} \rightarrow \infty$$
$$\check{a} = -\frac{p}{2}, \quad \check{b} = 0$$

\implies flache (und damit uninformative) Prior und maximaler Einfluss der Daten auf die Posterior:

$$\boldsymbol{\theta} \mid \sigma^2 \stackrel{a}{\sim} \mathcal{N}(\check{\boldsymbol{\mu}}, \sigma^2 \infty) \implies p(\boldsymbol{\theta} \mid \sigma^2) \propto 1$$

TODO: Bild

Erinnerung: *frequentistische* Regularisierung durch Minimierung von

$$\text{PLS}(\boldsymbol{\theta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) + \lambda \text{pen}(\boldsymbol{\theta})$$

mit Regularisierungs-Parameter $\lambda > 0$.

Bayesianische Regularisierung durch Wahl der Prior-Verteilung für $\boldsymbol{\theta}$

3. Ridge Regularisierung

Frequentistisch [8, 9]: $\text{pen}(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_2^2$

Bayesianisch [10]: $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$ mit $\tau^2 \propto \frac{1}{\lambda}$

4. Lasso Regularisierung

Frequentistisch [14]: $\text{pen}(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_1$

Bayesianisch [13]:

$$\boldsymbol{\theta} \mid \tau^2 \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$$

$$\tau_j^2 \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(0.5\lambda^2), \quad j = 1, \dots, p$$

Problem: keine Variablenselektion (im Gegensatz zu frequentistischem Lasso)

→ Alternative Priors für Variablenselektion: Spike and Slab [11], Horseshoe [1], u.v.m.

Vorteile von bayesianischer Regularisierung sind u.a.:

- Probabilistisches Modell trotz Regularisierung
- Regularisierungs-Parameter muss nicht als Hyperparameter optimiert werden (z.B. durch Prior auf τ^2)
- Mehr Anpassungsmöglichkeiten durch Prior-Spezifikation

TODO: Bild regularization Priors + update

Outline

1 Bayesianische **lineare** Modelle

2 Bayesianische **generalisierte** lineare Modelle (GLMs)

3 Posterior Inference

$$\text{LM: } \mathbf{y} \mid \boldsymbol{\theta}, \sigma^2 \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I}) \quad \rightarrow \quad \text{GLM: } \mathbf{y} \mid \boldsymbol{\theta} \sim F(g^{-1}(\mathbf{X}\boldsymbol{\theta}))$$

- Verteilungsannahme von \mathbf{y} wird (äquivalent zum frequentistischen GLM) auf alle Verteilungen F der Exponentialfamilie ausgeweitet
- Skala des linearen Prädiktors $\mathbf{X}\boldsymbol{\theta}$ wird mit der Link-Funktion g^{-1} angepasst

Bayesianisches logistisches Modell

$$\mathbf{y}_i \mid \boldsymbol{\theta} \sim \text{Bin}(1, g^{-1}(\mathbf{x}_i \boldsymbol{\theta})), \quad i = 1, \dots, n$$
$$g^{-1}(\mathbf{x}_i \boldsymbol{\theta}) = \sigma(\mathbf{x}_i \boldsymbol{\theta})$$

Für Beobachtungen $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^\top$ und Sigmoid-Link $\sigma(y) = \frac{\exp(y)}{1+\exp(y)}$

Prior Wahl

- Im Allgemeinen äquivalent zum LM möglich, z.B. Normalverteilung-Prior
- Verteilungen mit schweren Rändern (z.B. t-Verteilung, Cauchy Verteilung) verringern Separation und fördern Shrinkage [5, 7]
- Für Regularisierung können dieselben Priors verwendet werden [12, 4, 3]

- 1 Bayesianische **lineare** Modelle
- 2 Bayesianische **generalisierte** lineare Modelle (GLMs)
- 3 Posterior Inference

Erinnerung: Bayes-Regel

$$p(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{\int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}},$$

wobei $p(\mathbf{y} \mid \boldsymbol{\theta})$ die Modell-Likelihood ist.

bayesianisches LM: exakte Inferenz mit konjugierten Prioris

Metropolis Hastings (MCMC)

Idee: Approximation der Posterior mit Markov chain Monte Carlo - was muss man für Regression anpassen?

Laplace Approximation (LA)

Idee: Approximation der Posterior mit einer Normalverteilung

- Mittelwert und Varianz werden mit IWLS berechnet

PPD

- Bayesianische Regression (v.a. für praktische Anwendung): Gelman et al. [6]
- Prior Verteilungen (v.a. Shrinkage): Erp, Oberski, and Mulder [3] und Celeux et al. [2]
- Software: z.B. brms in R, PyMC in python

- [1] Carlos M. Carvalho, Nicholas G. Polson, and James G. Scott. “The horseshoe estimator for sparse signals”. English. In: *BIOMETRIKA* 97.2 (June 2010), pp. 465–480. ISSN: 0006-3444. DOI: 10.1093/biomet/asq017.
- [2] Gilles Celeux et al. “Regularization in Regression: Comparing Bayesian and Frequentist Methods in a Poorly Informative Situation”. In: *Bayesian Analysis* 7.2 (June 2012), pp. 477–502. ISSN: 1936-0975, 1931-6690. DOI: 10.1214/12-BA716.
- [3] Sara van Erp, Daniel L. Oberski, and Joris Mulder. “Shrinkage priors for Bayesian penalized regression”. In: *Journal of Mathematical Psychology* 89 (Apr. 2019), pp. 31–50. ISSN: 0022-2496. DOI: 10.1016/j.jmp.2018.12.004.
- [4] Ludwig Fahrmeir, Thomas Kneib, and Susanne Konrath. “Bayesian regularisation in structured additive regression: a unifying perspective on shrinkage, smoothing and predictor selection”. In: *Statistics and Computing* 20.2 (2010), pp. 203–219. ISSN: 1573-1375. DOI: 10.1007/s11222-009-9158-3.

- [5] Andrew Gelman et al. “A weakly informative default prior distribution for logistic and other regression models”. In: *The Annals of Applied Statistics* 2.4 (Dec. 2008), pp. 1360–1383. ISSN: 1932-6157, 1941-7330. DOI: 10.1214/08-AOAS191.
- [6] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. New York: Chapman and Hall/CRC, 2013. ISBN: 978-0-429-11307-9. DOI: 10.1201/b16018.
- [7] Joyee Ghosh, Yingbo Li, and Robin Mitra. *On the Use of Cauchy Prior Distributions for Bayesian Logistic Regression*. Feb. 2017. DOI: 10.48550/arXiv.1507.07170.
- [8] Arthur E. Hoerl and Robert W. Kennard. “Ridge Regression: Applications to Nonorthogonal Problems”. In: *Technometrics* 12.1 (1970), pp. 69–82. ISSN: 0040-1706. DOI: 10.2307/1267352.
- [9] Arthur E. Hoerl and Robert W. Kennard. “Ridge Regression: Biased Estimation for Nonorthogonal Problems”. In: *Technometrics* 12.1 (1970), pp. 55–67. ISSN: 0040-1706. DOI: 10.2307/1267351.
- [10] David J. C. MacKay. “Bayesian Interpolation”. In: *Neural Computation* 4.3 (May 1992), pp. 415–447. ISSN: 0899-7667. DOI: 10.1162/neco.1992.4.3.415.

- [11] Tj Mitchell and Jj Beauchamp. “Bayesian Variable Selection in Linear-Regression”. English. In: *Journal of the American Statistical Association* 83.404 (Dec. 1988), pp. 1023–1032. ISSN: 0162-1459. DOI: 10.2307/2290129.
- [12] R. B. O’Hara and M. J. Sillanpää. “A review of Bayesian variable selection methods: what, how and which”. In: *Bayesian Analysis* 4.1 (Mar. 2009), pp. 85–117. ISSN: 1936-0975, 1931-6690. DOI: 10.1214/09-BA403.
- [13] Trevor Park and George Casella. “The Bayesian Lasso”. English. In: *Journal of the American Statistical Association* 103.482 (June 2008), pp. 681–686. ISSN: 0162-1459. DOI: 10.1198/0162145080000000337.
- [14] Robert Tibshirani. “Regression Shrinkage and Selection via the Lasso”. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 58.1 (1996), pp. 267–288. ISSN: 0035-9246.