

Bayesianische Regression

lineare und logistische Modelle

Lona Koers

LMU

25. Juli 2025

TODO: gutes Intro-Beispiel

- Generalisierte Lineare Modelle (GLMs)
- Punktvorhersage vs. Verteilung vorhersagen
- warum reicht uns ein CI / PI

- 1 Bayesianisches **lineares** Modell (LM)
- 2 Bayesianische **generalisierte** lineare Modelle (GLMs)
- 3 Inferenz der Parameter Posterior
- 4 Referenzen
- 5 Anhang

Annahmen:

- ① i.i.d. Daten $\mathbf{D} = (\mathbf{y}, \mathbf{X})$
- ② Kondition auf \mathbf{X} (implizit)

Frequentistisches lineares Modell: $\mathbf{y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$

- ③ Gewichtsparameter $\boldsymbol{\theta}$ als Zufallsvariable interpretieren

Bayesianisches lineares Modell:

$$\mathbf{y} \mid \boldsymbol{\theta}, \sigma^2 \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$$

Prior-Annahme für θ (und evtl. σ^2) notwendig \rightarrow sehr vielseitige Modell-Anpassung möglich

Normal-Invers-Gamma Prior:

$$\theta \mid \sigma^2 \sim \mathcal{N}(\check{\mu}, \sigma^2 \check{\Sigma})$$

$$\sigma^2 \sim \text{IG}(\check{a}, \check{b})$$

$$\theta, \sigma^2 \sim \text{NIG}(\check{\mu}, \sigma^2 \check{\Sigma}, \check{a}, \check{b})$$

mit Prior Parametern: $\check{\mu}$, $\check{\Sigma}$, \check{a} und \check{b}

Vorteil: NIG-Prior ist mit Normalverteilungs-Likelihood konjugiert \rightarrow exakte Inferenz möglich
(mehr dazu später)

TODO: Bild

(TODO: relevant?)

Uninformative Prior

z.B. mit NIG-Prior mit Prior Parametern

$$\check{\mu} = \mathbf{0}, \quad \check{\Sigma}^{-1} = \mathbf{0} \text{ i.e. } \check{\Sigma} \rightarrow \infty, \quad \check{a} = -\frac{p}{2}, \quad \check{b} = 0$$

⇒ flache (und damit uninformative) Prior und maximaler Einfluss der Daten auf die Posterior:

$$\boldsymbol{\theta} \mid \sigma^2 \stackrel{a}{\sim} \mathcal{N}(\check{\mu}, \sigma^2 \infty) \implies p(\boldsymbol{\theta} \mid \sigma^2) \propto 1$$

TODO: Bild

Erinnerung: Regularisierung im *frequentistischen* LM durch Minimierung von

$$\text{PLS}(\boldsymbol{\theta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) + \lambda \text{pen}(\boldsymbol{\theta})$$

mit Regularisierungs-Parameter $\lambda > 0$.

Bayesianische Regularisierung durch Wahl der Prior-Verteilung für $\boldsymbol{\theta}$

Regularisierung durch Wahl der Prior-Verteilung

Ridge Regularisierung

- Frequentistisch [15, 16]: $\text{pen}(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_2^2$
- Bayesianisch [19]: $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$ mit $\tau^2 \propto \frac{1}{\lambda}$

Lasso Regularisierung

- Frequentistisch [26]: $\text{pen}(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_1$
- Bayesianisch [23]:

$$\boldsymbol{\theta} \mid \tau^2 \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$$

$$\tau_j^2 \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(0.5\lambda^2), \quad j = 1, \dots, p$$

Problem: keine Variablenselektion (im Gegensatz zu frequentistischem Lasso)

→ Alternative Priors für Variablenselektion: Spike and Slab [20], Horseshoe [4], u.v.m.

TODO: Bild regularization Priors + update

(TODO: relevant? -> Anhang bzw. Diskussion)

Vorteile von bayesianischer Regularisierung sind u.a.:

- Probabilistisches Modell trotz Regularisierung
- Regularisierung-Parameter muss nicht als Hyperparameter optimiert werden (z.B. durch Prior auf τ^2)
- Mehr Anpassungsmöglichkeiten durch Prior-Spezifikation

- 1 Bayesianisches **lineares** Modell (LM)
- 2 Bayesianische **generalisierte** lineare Modelle (GLMs)
- 3 Inferenz der Parameter Posterior
- 4 Referenzen
- 5 Anhang

$$\text{LM: } \mathbf{y} \mid \boldsymbol{\theta}, \sigma^2 \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I}) \quad \rightarrow \quad \text{GLM: } \mathbf{y} \mid \boldsymbol{\theta} \sim F(g^{-1}(\mathbf{X}\boldsymbol{\theta}))$$

- Verteilungsannahme von \mathbf{y} wird (äquivalent zum frequentistischen GLM) auf alle Verteilungen F der Exponentialfamilie ausgeweitet
- Skala des linearen Prädiktors $\mathbf{X}\boldsymbol{\theta}$ wird mit der Link-Funktion g^{-1} angepasst

Bayesianisches logistisches Modell

$$\mathbf{y}_i \mid \boldsymbol{\theta} \sim \text{Bin}(1, g^{-1}(\mathbf{x}_i \boldsymbol{\theta})), \quad i = 1, \dots, n$$
$$g^{-1}(\mathbf{x}_i \boldsymbol{\theta}) = \sigma(\mathbf{x}_i \boldsymbol{\theta})$$

Für Beobachtungen $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^\top$ und Sigmoid-Link $\sigma(y) = \frac{\exp(y)}{1 + \exp(y)}$

Prior Wahl

- I.A. äquivalent zum LM möglich, z.B. Normalverteilungs-Prior
- Verteilungen mit schweren Rändern (z.B. t-Verteilung, Cauchy Verteilung) adressieren
Separation und fördern Shrinkage [11, 13]
- Für Regularisierung können dieselben Priors wie im LM verwendet werden [22, 8, 7]

TODO: Bild mti decision boundard? Lieber nicht ...

- 1 Bayesianisches **lineares** Modell (LM)
- 2 Bayesianische **generalisierte** lineare Modelle (GLMs)
- 3 Inferenz der Parameter Posterior
- 4 Referenzen
- 5 Anhang

Erinnerung

- Bayes-Regel zur Ermittlung der Parameter Posterior

$$p(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{\int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}} = \frac{\mathcal{L}(\boldsymbol{\theta}) p(\boldsymbol{\theta})}{\int \mathcal{L}(\boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}}$$

- Inferenz im frequentistischen LM: z.B. kleinste Quadrate Schätzung mit

$$\hat{\boldsymbol{\theta}}_{KQ} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \quad \text{mit} \quad \hat{\boldsymbol{\theta}}_{KQ} \sim \mathcal{N}(\boldsymbol{\theta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$$

Inferenz mit konjugierten Priors

Bayesianisches LM: Nutzung der Konjugiertheit von $\mathbf{y} \mid \boldsymbol{\theta}, \sigma^2 \sim \mathcal{N}$ und $\boldsymbol{\theta}, \sigma^2 \sim \text{NIG}$

$$\boldsymbol{\theta}, \sigma^2 \mid \mathbf{y} \sim \text{NIG}(\hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}}, \hat{a}, \hat{b})$$

mit

$$\hat{\boldsymbol{\mu}} = \hat{\boldsymbol{\Sigma}}(\check{\boldsymbol{\Sigma}}^{-1}\check{\boldsymbol{\mu}} + \mathbf{X}^\top \mathbf{y}), \quad \hat{\boldsymbol{\Sigma}} = (\mathbf{X}^\top \mathbf{X} + \check{\boldsymbol{\Sigma}}^{-1})^{-1}$$

- **uninformative NIG-Prior:** Posterior Mean und KQ-Schätzer sind äquivalent:

$$\check{\boldsymbol{\mu}} = \mathbf{0}, \quad \check{\boldsymbol{\Sigma}}^{-1} = \mathbf{0} \implies \hat{\boldsymbol{\mu}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \hat{\boldsymbol{\Sigma}} = (\mathbf{X}^\top \mathbf{X})^{-1}$$

- **Ridge:** Spezialfall der NIG-Prior \rightarrow konjugierte Berechnung der Parameter Posterior
- **Lasso:** Prior hat keine geschlossene Form, aus der Posterior kann aber einfach mit Gibbs-Sampling simuliert werden [23]

Problem: Inferenz mit konjugierten Priors ist nur sehr selten möglich [**polson_bayesian_2013**]

→ **Approximative bayesianische Inferenz**, um aus der Posterior zu sampeln, mit z.B.:

- Markov chain Monte Carlo Methoden
 - ▶ **Metropolis-Hastings Algorithmus** [14]
 - ▶ Gibbs Sampling (bedingte Konjugiertheit) [6]
 - ▶ Hamiltonian Monte Carlo (v.a. hochdimensionale Posterior) [21]
- Data Augmentation mit latenten Variablen, um künstlich Konjugiertheit zu induzieren [1, 17, 9, 25]
- **Laplace Approximation** [**tierney_accurate_1986**]

- **Idee:** Aus der Posterior $p(\boldsymbol{\theta} \mid \mathbf{y})$ ziehen, ohne Annahmen über ihre exakte Form machen zu müssen
- **Problem:** Ergebnisse sind am Besten, wenn die Posterior bis auf eine Konstante (meist die Normalisierungskonstante $\int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}$) bekannt sind
- **Inputs:**
 - ▶ Anzahl der Ziehungen $K \rightarrow$ frei wählbar
 - ▶ Likelihood $p(\boldsymbol{\theta} \mid \mathbf{y})$ und Prior $p(\boldsymbol{\theta}) \rightarrow$ bekannt
 - ▶ Proposal Verteilung $q \rightarrow$ muss sorgfältig gewählt werden

Effizienz des Algorithmus ist stark abhängig von der Proposal Verteilung.

→ **Optionen:**

- **Normalverteilung**

$$q(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(k)}) \sim \mathcal{N}(\boldsymbol{\theta}^{(k)} \mid -H^{-1}(\boldsymbol{\theta}^{(k)}))$$

mit Mittelwert beim letzten Sample. Die Hesse-Matrix H von $p(\boldsymbol{\theta} \mid \mathbf{y})$ wird meist mit IWLS geschätzt [10, 18, 25]

- Scott [25] schlägt **Verteilungen mit schweren Rändern** vor → mehr Mixing, kürzerer Burn-in und schnellere Konvergenz

- **Idee:** Approximation der Posterior mit einer Normalverteilung

$$p(\boldsymbol{\theta} \mid \mathbf{y}) \approx \mathcal{N}(\hat{\boldsymbol{\theta}}_{MAP}, H^{-1}(\hat{\boldsymbol{\theta}}_{MAP}))$$

mit Maximum-a-Posteriori Schätzer $\hat{\boldsymbol{\theta}}_{MAP}$ und Hesse-Matrix H von $p(\boldsymbol{\theta} \mid \mathbf{y})$

- Erweiterung für hierarchische Modelle: Integrated Nested Laplace Approximation (INLA) [24]

Setup: 1.000 synthetische Datensätze mit $n = 100$ und

$$\mathbf{X} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \boldsymbol{\theta} = (-0.5, 2, 1)$$

$$\text{linear: } \mathbf{y} \mid \boldsymbol{\theta} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\theta}, \mathbf{I})$$

$$\text{logistic: } \mathbf{y} \mid \boldsymbol{\theta} \sim \text{Ber}(\sigma(\mathbf{X}\boldsymbol{\theta}))$$


Experiment: für jeden Datensatz wurde angepasst:

- Ein lineares und ein logistisches Regressionsmodell mit $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, 10 \cdot \mathbf{I})$ und $\sigma^2 = 10$
- Mit Laplace Approximation und Metropolis-Hastings ($K = 5.000$, Burn-in = 500, Thinning Intervall = 10)


Beispiel 2: LA vs. Metropolis-Hastings

Lineares Modell


Elapsed time






Parameter estimates



Posterior parameter standard deviation



Logistisches Modell



Vorhersagen mit bayesianischen Modellen

Aus der Bayes Regel:

$$p(\mathbf{y}) = \int p(\mathbf{y}, \boldsymbol{\theta}) d\boldsymbol{\theta} = \int p(\mathbf{y} | \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}$$

Posterior Predictive Distribution

→ Vorhersagen für $\tilde{\mathbf{X}}$ im Bayesianischen GLM [3, 2]

$$p(\tilde{\mathbf{y}} | \mathbf{y}) = \int p(\tilde{\mathbf{y}}, \boldsymbol{\theta} | \mathbf{y}) d\boldsymbol{\theta} = \int p(\tilde{\mathbf{y}} | \boldsymbol{\theta}, \mathbf{y}) p(\boldsymbol{\theta}) d\boldsymbol{\theta} \stackrel{\tilde{\mathbf{y}} \perp \mathbf{y} | \boldsymbol{\theta}}{=} \int p(\tilde{\mathbf{y}} | \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}$$

Für das bayesianische **logistische Modell** berechnet man

$$p(\tilde{\mathbf{y}} = 1 | \mathbf{y})$$

mit $y_i \in \{0 \text{ (negative)}, 1 \text{ (positive)}\}$

TODO: Bild

Analytische Berechnung: z.B. für die NIG-Prior ergibt sich

$$\tilde{\mathbf{y}} \mid \boldsymbol{\theta}, \sigma^2, \mathbf{y} \sim \mathcal{T}(2\hat{a}, \tilde{\mathbf{X}}\boldsymbol{\theta}, \frac{\hat{b}}{\hat{a}}(\mathbf{I} + \tilde{\mathbf{X}}\hat{\Sigma}\tilde{\mathbf{X}}^\top))$$

Alternativ (und viel wichtiger): **Approximation**

- für Metropolis-Hastings: $p(\tilde{\mathbf{y}} = 1 \mid \boldsymbol{\theta}, \mathbf{y}) \approx \frac{1}{K} \sum_{k=1}^K \sigma(\tilde{\mathbf{X}}\boldsymbol{\theta}^{(k)})$
- für Laplace Approximation:
 - ▶ LA-approximierte PPD analytisch berechnen:

$$p(\tilde{\mathbf{y}} = 1 \mid \boldsymbol{\theta}, \mathbf{y}) = \int \sigma(\tilde{\mathbf{X}}\boldsymbol{\theta}) \mathcal{N}_{\boldsymbol{\theta}}(\hat{\boldsymbol{\theta}}_{MAP}, H^{-1}(\hat{\boldsymbol{\theta}}_{MAP})) d\boldsymbol{\theta}$$

- ▶ Samples $\boldsymbol{\theta}^{(s)} \sim \mathcal{N}(\hat{\boldsymbol{\theta}}_{MAP}, H^{-1}(\hat{\boldsymbol{\theta}}_{MAP}))$ mit $s = 1, \dots, S$ aus der LA-approximierten Parameter Posterior ziehen und wie bei Metropolis-Hastings vorgehen

- Bayesianische Regression (v.a. für praktische Anwendung): Gelman et al. [12]
- Prior Verteilungen (v.a. Shrinkage): Erp, Oberski, and Mulder [7] und Celeux et al. [5]
- Software: z.B. brms in R, PyMC in python

- 1 Bayesianisches **lineares** Modell (LM)
- 2 Bayesianische **generalisierte** lineare Modelle (GLMs)
- 3 Inferenz der Parameter Posterior
- 4 Referenzen
- 5 Anhang

- 1 Bayesianisches **lineares** Modell (LM)
- 2 Bayesianische **generalisierte** lineare Modelle (GLMs)
- 3 Inferenz der Parameter Posterior
- 4 Referenzen
- 5 **Anhang**

Herleitung der konjugierten Priori

Posterior Inference: exakter Metropolis (-Hastings) Algorithmus

- ➊ Initialize $\boldsymbol{\theta}^{(1)}$
- ➋ For $k = 1, \dots, K$
 - ➊ Draw $\boldsymbol{\theta}^{(*)}$ from the *proposal distribution* $q(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(k)})$
 - ➋ calculate the *acceptance probability*

$$\alpha = \min\left(1, \frac{p(\boldsymbol{\theta}^{(*)} \mid \mathbf{y}) p(\boldsymbol{\theta}^{(*)}) q(\boldsymbol{\theta}^{(k)} \mid \boldsymbol{\theta}^{(*)})}{p(\boldsymbol{\theta}^{(k)} \mid \mathbf{y}) p(\boldsymbol{\theta}^{(k)}) q(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(k)})}\right)$$

- ➌ Accept or discard the proposal $\boldsymbol{\theta}^{(*)}$ (for $u \sim \text{Uni}[0, 1]$)

$$\begin{cases} u \leq \alpha & \boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(*)} \\ u > \alpha & \boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} \end{cases}$$

Und z.B.

$$q(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(k)}) \sim \mathcal{N}(\boldsymbol{\theta}^{(k)} \mid -H^{-1}(\boldsymbol{\theta}^{(k)}))$$

mit $H(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}}^2 \log(p(\boldsymbol{\theta}^{(k)} \mid \mathbf{y}) p(\boldsymbol{\theta}^{(k)}))$

Exemplarische Berechnung für ein bayesianisches logistisches Modell mit der Prior $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$:

Es gilt dass mit Laplace Approximation $p(\boldsymbol{\theta} \mid \mathbf{y}) \approx \mathcal{N}(\hat{\boldsymbol{\theta}}_{MAP}, H^{-1}(\hat{\boldsymbol{\theta}}_{MAP}))$ mit

$$\begin{aligned}\hat{\boldsymbol{\theta}}_{MAP} &= \arg \max_{\boldsymbol{\theta}} p(\boldsymbol{\theta} \mid \mathbf{y}) \stackrel{\text{Bayes' rule}}{=} \arg \max_{\boldsymbol{\theta}} p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta} \\ &= \arg \max_{\boldsymbol{\theta}} \sum_{i=1}^n \log(\sigma(y_i \mathbf{x}_i \boldsymbol{\theta})) - \frac{1}{2\sigma^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} \\ H(\boldsymbol{\theta}) &= -\nabla_{\boldsymbol{\theta}}^2 \log p(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{1}{\sigma^2} \mathbf{I} + \sum_{i=1}^n \sigma(y_i \mathbf{x}_i \boldsymbol{\theta}) (1 - \sigma(y_i \mathbf{x}_i \boldsymbol{\theta})) \mathbf{x}_i \mathbf{x}_i^\top.\end{aligned}$$

Beispiel 1: Regularisierung in data-sparse Szenarien

Experiment-Setup: approximate Inference

- [1] James H. Albert and Siddhartha Chib. “Bayesian Analysis of Binary and Polychotomous Response Data”. In: *Journal of the American Statistical Association* 88.422 (1993), pp. 669–679. ISSN: 0162-1459. DOI: 10.2307/2290350.
- [2] Maria Maddalena Barbieri. “Posterior Predictive Distribution”. In: *Wiley StatsRef: Statistics Reference Online*. John Wiley & Sons, Ltd, 2015, pp. 1–6. ISBN: 978-1-118-44511-2. DOI: 10.1002/9781118445112.stat07839.
- [3] George E. P. Box. “Sampling and Bayes’ Inference in Scientific Modelling and Robustness”. In: *Journal of the Royal Statistical Society. Series A (General)* 143.4 (1980), pp. 383–430. ISSN: 0035-9238. DOI: 10.2307/2982063.
- [4] Carlos M. Carvalho, Nicholas G. Polson, and James G. Scott. “The horseshoe estimator for sparse signals”. English. In: *BIOMETRIKA* 97.2 (June 2010), pp. 465–480. ISSN: 0006-3444. DOI: 10.1093/biomet/asq017.
- [5] Gilles Celeux et al. “Regularization in Regression: Comparing Bayesian and Frequentist Methods in a Poorly Informative Situation”. In: *Bayesian Analysis* 7.2 (June 2012), pp. 477–502. ISSN: 1936-0975, 1931-6690. DOI: 10.1214/12-BA716.

- [6] P. Dellaportas and A. F. M. Smith. “Bayesian Inference for Generalized Linear and Proportional Hazards Models via Gibbs Sampling”. In: *Journal of the Royal Statistical Society. Series C (Applied Statistics)* 42.3 (1993), pp. 443–459. ISSN: 0035-9254. DOI: 10.2307/2986324.
- [7] Sara van Erp, Daniel L. Oberski, and Joris Mulder. “Shrinkage priors for Bayesian penalized regression”. In: *Journal of Mathematical Psychology* 89 (Apr. 2019), pp. 31–50. ISSN: 0022-2496. DOI: 10.1016/j.jmp.2018.12.004.
- [8] Ludwig Fahrmeir, Thomas Kneib, and Susanne Konrath. “Bayesian regularisation in structured additive regression: a unifying perspective on shrinkage, smoothing and predictor selection”. In: *Statistics and Computing* 20.2 (2010), pp. 203–219. ISSN: 1573-1375. DOI: 10.1007/s11222-009-9158-3.
- [9] Sylvia Frühwirth-Schnatter and Rudolf Frühwirth. “Auxiliary mixture sampling with applications to logistic models”. In: *Computational Statistics & Data Analysis* 51.7 (Apr. 2007), pp. 3509–3528. ISSN: 0167-9473. DOI: 10.1016/j.csda.2006.10.006.
- [10] Dani Gamerman. “Markov chain Monte Carlo for dynamic generalised linear models”. In: *Biometrika* 85.1 (Mar. 1998), pp. 215–227. ISSN: 0006-3444. DOI: 10.1093/biomet/85.1.215.

- [11] Andrew Gelman et al. “A weakly informative default prior distribution for logistic and other regression models”. In: *The Annals of Applied Statistics* 2.4 (Dec. 2008), pp. 1360–1383. ISSN: 1932-6157, 1941-7330. DOI: 10.1214/08-AOAS191.
- [12] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. New York: Chapman and Hall/CRC, 2013. ISBN: 978-0-429-11307-9. DOI: 10.1201/b16018.
- [13] Joyee Ghosh, Yingbo Li, and Robin Mitra. *On the Use of Cauchy Prior Distributions for Bayesian Logistic Regression*. Feb. 2017. DOI: 10.48550/arXiv.1507.07170.
- [14] W. K. Hastings. “Monte Carlo Sampling Methods Using Markov Chains and Their Applications”. In: *Biometrika* 57.1 (1970), pp. 97–109. ISSN: 0006-3444. DOI: 10.2307/2334940.
- [15] Arthur E. Hoerl and Robert W. Kennard. “Ridge Regression: Applications to Nonorthogonal Problems”. In: *Technometrics* 12.1 (1970), pp. 69–82. ISSN: 0040-1706. DOI: 10.2307/1267352.
- [16] Arthur E. Hoerl and Robert W. Kennard. “Ridge Regression: Biased Estimation for Nonorthogonal Problems”. In: *Technometrics* 12.1 (1970), pp. 55–67. ISSN: 0040-1706. DOI: 10.2307/1267351.

- [17] CC Holmes and Leonhard Knorr-Held. “Efficient simulation of Bayesian Logistic Regression Models”. In: (Jan. 2003).
- [18] Peter J. Lenk and Wayne S. DeSarbo. “Bayesian Inference for Finite Mixtures of Generalized Linear Models with Random Effects”. en. In: *Psychometrika* 65.1 (Mar. 2000), pp. 93–119. ISSN: 0033-3123, 1860-0980. DOI: 10.1007/BF02294188.
- [19] David J. C. MacKay. “Bayesian Interpolation”. In: *Neural Computation* 4.3 (May 1992), pp. 415–447. ISSN: 0899-7667. DOI: 10.1162/neco.1992.4.3.415.
- [20] Tj Mitchell and Jj Beauchamp. “Bayesian Variable Selection in Linear-Regression”. English. In: *Journal of the American Statistical Association* 83.404 (Dec. 1988), pp. 1023–1032. ISSN: 0162-1459. DOI: 10.2307/2290129.
- [21] Radford M Neal. “Probabilistic inference using Markov chain Monte Carlo methods”. In: *Department of Computer Science, University of Toronto Toronto, Ontario, Canada* (1993).
- [22] R. B. O’Hara and M. J. Sillanpää. “A review of Bayesian variable selection methods: what, how and which”. In: *Bayesian Analysis* 4.1 (Mar. 2009), pp. 85–117. ISSN: 1936-0975, 1931-6690. DOI: 10.1214/09-BA403.

- [23] Trevor Park and George Casella. “The Bayesian Lasso”. English. In: *Journal of the American Statistical Association* 103.482 (June 2008), pp. 681–686. ISSN: 0162-1459. DOI: 10.1198/016214508000000337.
- [24] Håvard Rue, Sara Martino, and Nicolas Chopin. “Approximate Bayesian Inference for Latent Gaussian models by using Integrated Nested Laplace Approximations”. In: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 71.2 (Apr. 2009), pp. 319–392. ISSN: 1369-7412. DOI: 10.1111/j.1467-9868.2008.00700.x.
- [25] Steven L. Scott. “Data augmentation, frequentist estimation, and the Bayesian analysis of multinomial logit models”. en. In: *Statistical Papers* 52.1 (Feb. 2011), pp. 87–109. ISSN: 1613-9798. DOI: 10.1007/s00362-009-0205-0.
- [26] Robert Tibshirani. “Regression Shrinkage and Selection via the Lasso”. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 58.1 (1996), pp. 267–288. ISSN: 0035-9246.